

Proyecto 2 : Análisis de señales ECG

Erika F. Gomez Cardenas ^{1, *}, Angie P. Triana Peñaloza ^{1, *}, Ana C. Mejia Agudelo ^{1, *}

¹Facultad de ingeniería, Universidad de Antioquia UdeA, calle 70 No. 52-21, Medellín, Colombia

*erika.gomez@udea.edu.co, angiep.trianap@udea.edu.co, ana.mejiaa@udea.edu.co

1. Revisión bibliográfica

1.1 Prediction of atrial fibrillation from at-home single-lead ECG signals without arrhythmias

1.1.1 Resumen

En el artículo se desarrolló un modelo para estimar el riesgo de un individuo de desarrollar fibrilación auricular (FA) dentro de un periodo de observación de 2 semanas empleando intervalos de señales de ECG de una sola derivación, anotaciones clínicas y características demográficas como entrada [1].

1.1.2. Diagrama de flujo metodológico

Diagrama de flujo: Modelo para estimar el riesgo de un individuo de desarrollar fibrilación auricular (FA) dentro de un periodo de 2 semanas

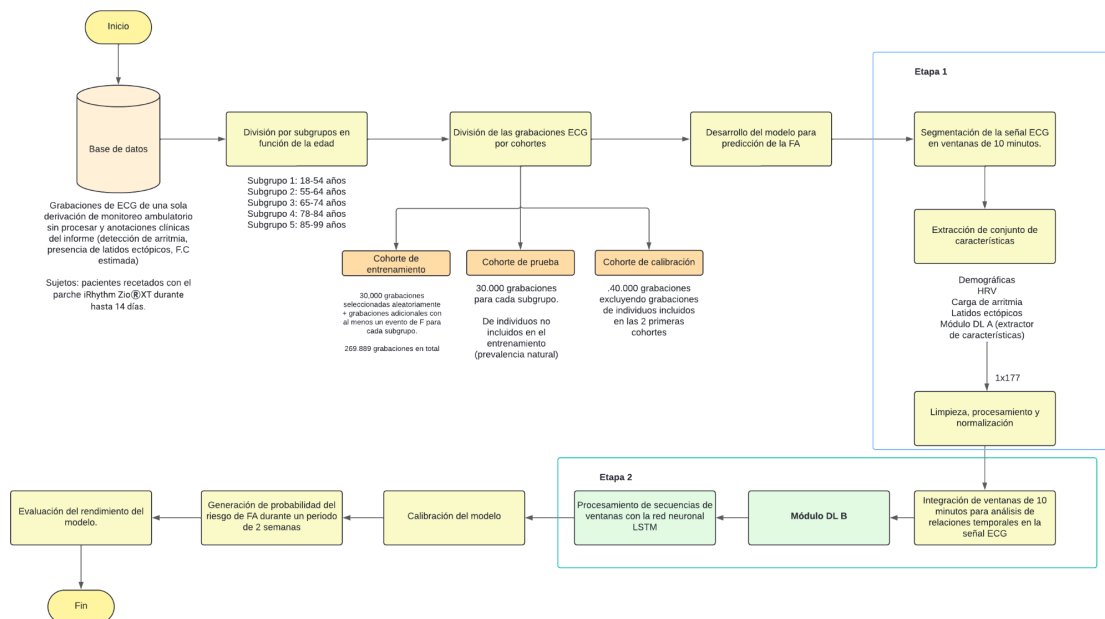


Figura 1. Diagrama de flujo para la metodología desarrollada en el artículo “Prediction of atrial fibrillation from at-home single-lead ECG signals without arrhythmias”

1.1.3. Descripción de la metodología:

Para el desarrollo del modelo se hizo la recolección de datos de ECG, los cuales fueron grabaciones adquiridas desde enero de 2019 a mayo de 2022, tomadas a personas a las cuales se les recetó el parche iRhythm de una sola derivación para monitoreo ambulatorio de hasta 14 días. Se tomaron únicamente grabaciones de personas con FA paroxística (carga < 70%). Posteriormente se hizo la división por subgrupos en función de la edad, obteniendo 5 subgrupos (18-54 años, 55-64 años, 65-74 años, 78-84 años, 85-99 años), con el propósito de entrenar y validar un modelo por separado para cada subgrupo, para considerar en el desarrollo del modelo la varianza de características de FA sujetas a la edad y garantizar un rendimiento preciso y confiable del modelo en diferentes rangos de edad.

Las grabaciones fueron divididas en 3 cohortes: cohorte de entrenamiento (enriquecida con grabaciones aleatorias de cada subgrupo + grabaciones adicionales disponibles con al menos un evento de FA), cohorte de calibración (grabaciones de individuos no incluidos en la cohorte de entrenamiento) y cohorte de prueba (grabaciones seleccionadas al azar después de la exclusión de grabaciones de individuos seleccionadas en las primeras 2 cohortes).

El desarrollo del modelo de predicción se hizo a partiendo de señales ECG de intervalos de hasta 24 horas, que fueron segmentados en ventanas de 10 minutos (puesto que se ha descubierto empíricamente que este marco de tiempo permite calcular suficiente información temporal y mantiene la secuencia suficientemente corta para que la RNN la analice de manera eficiente) para realizar la extracción de datos. Constó de dos etapas, inicialmente se extrajeron características demográficas, HVR, métricas relacionadas con otros ritmos anormales, latidos ectópicos, y adicionalmente se empleó el primer módulo de aprendizaje profundo (módulo DL A, extractor de características) para descubrir de manera automática características representativas y compactas del ECG de entrada. Posteriormente se hizo un preprocesamiento, llevando a cabo la normalización y limpieza de los datos. Se excluyeron ECG excesivamente ruidosas o con gran cantidad de artefactos.

Una vez realizado lo anterior, se hizo la integración de las ventanas y las características extraídas se utilizaron en la segunda etapa para alimentar el módulo DL B, el cual procesó la secuencia resultante de ventanas para capturar variaciones temporales complejas a lo largo de la señal mediante la red neuronal de memoria a corto plazo (LSTM, por sus siglas en inglés). Posteriormente se hizo la calibración del modelo para mapear el resultado del modelo a una probabilidad de riesgo real para cada subgrupo.

Finalmente, se validó el rendimiento del modelo evaluando: la importancia predictiva de las características consideradas a la entrada (se compararon 6 configuraciones, siendo la más efectiva la All Features), el impacto de la duración de adquisición en la capacidad de predicción del modelo (10 minutos, 1 hora y 24 horas), y la relación entre el desempeño del modelo y la carga de

FA (baja, media, alta). Para comparar los desempeños del modelo en los diferentes casos se utilizaron métricas de precisión promedio y AUC.

1.2 Optimal Multi-Stage Arrhythmia Classification Approachs

1.2.1. Resumen

En el estudio se emplearon diversas técnicas de reducción de ruido en las señales de ECG, se planteó un nuevo modelo de extracción de características interpretativo y se implementó un estudio de comparación computacional de diversos esquemas de clasificación competitivos basados en datos de señales ECG de 12 derivaciones etiquetados por un cardiólogo, seccionados en 4 grupos de arritmia : SB, FA, GSVT y SR (en algunos se fusionaron casos raros de arritmia en tipos de arritmia de nivel superior) [2].

1.2.2. Diagrama de flujo metodológico

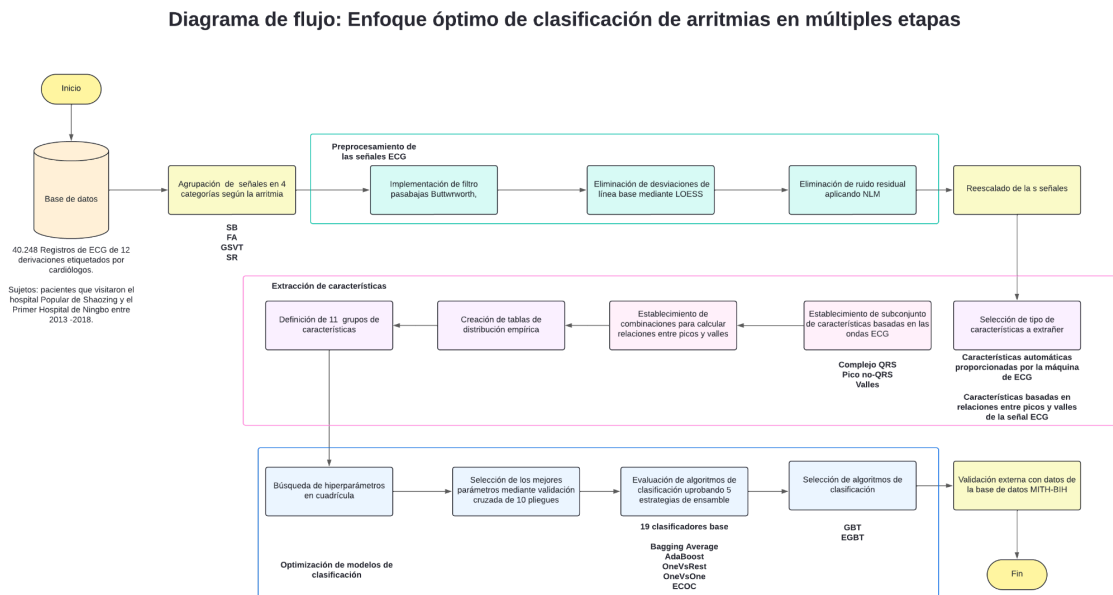


Figura 2. Diagrama de flujo para la metodología desarrollada en el artículo “Optimal Multi-Stage Arrhythmia Classification Approachs”

1.2.2. Descripción de la metodología

Para el diseño del estudio se seleccionaron 40.258 registros de ECG de 12 derivaciones tomados a participantes seleccionados aleatoriamente entre 120.000 sujetos que fueron pacientes entre 2013 y 2018 de los hospitales Popular Shaoxing y el primer hospital de Ningbo. Las señales ECG tenían una frecuencia de muestreo de 500 Hz y estaban etiquetadas por cardiólogos, los 11 ritmos en las etiquetas se agruparon en 4 tipos de ritmo: SB, FA, GSVT y SR. Posteriormente se hizo el preprocesamiento de las señales, eliminando el ruido de alta frecuencia con el filtro pasa bajas

Butterworth, aplicando LOESS para eliminar tendencias lineales y el NLM para remover el ruido restante.

En la extracción de características se tuvieron en cuenta varias consideraciones. Se extrajeron dos tipos de características: automáticas, correspondientes a las mediciones proporcionadas directamente por el equipo de ECG (F.C en BPM, duración complejo QRS, intervalo QT, número de complejos QRS detectados). A partir de estas se hicieron 3 subconjuntos: complejo QRS, picos no-QRS y Valles. Y características derivadas en base a relaciones entre los picos y valles de las señales, incluyendo su altura, ancho y prominencia.

Se hizo un cálculo de relaciones entre picos y valles en seis combinaciones distintas:

Para cada combinación se calcularon relaciones entre:

- QRS vs QRS
- Picos no-QRS vs Picos no-QRS
- Valles vs Valles
- QRS vs Picos no-QRS
- QRS vs Valles
- Picos no QRS vs Valles

Luego, para cada una de ellas se calcularon relaciones de relevancia:

- La diferencia de altura con la diferencia de tiempo entre picos y valles.
- Diferencia anchura sobre diferencia de tiempo.
- Diferencia de prominencia sobre diferencia de tiempo.

Para las relaciones se formó una tabla de distribución de frecuencia empírica para tener una longitud uniforme de características para alimentar el modelo de clasificación, ya que las relaciones en sí mismas no podían emplearse como entradas de características por su elevada varianza entre pacientes.

Se hizo un reescalado de las señales, seguido de una búsqueda de hiperparámetros en cuadrícula para ajustar los parámetros de los clasificadores, estos se seleccionaron utilizando validación cruzada 10 veces. Finalmente se evaluó el rendimiento de distintos clasificadores base como DT, KNN, RF, GBT, probando distintas estrategias de ensamble (5), se concluyó que los mejores eran GBT y EGBT y se hizo la validación externa del modelo.

1.3 Prediction of atrial fibrillation from at-home single-lead ECG signals without arrhythmias

1.3.1. Resumen

Este estudio se basó en el uso de una red neuronal convolucional (CNN) para clasificar diferentes arritmias sin depender de la detección de la onda QRS, utilizando datos de ECG de las bases de datos de PhysioNet. Se entrenaron modelos con segmentos de 5 y 10 segundos, y ambos mostraron una precisión promedio del 97.31%. El modelo fue capaz de diferenciar entre ritmos normales y varias arritmias como fibrilación auricular, aleteo auricular, y taquicardia ventricular, entre otras. Los resultados demuestran que es posible detectar arritmias con grabaciones cortas de ECG, lo que es ideal para dispositivos portátiles y situaciones de emergencia [3].

1.3.2. Diagrama de flujo metodológico

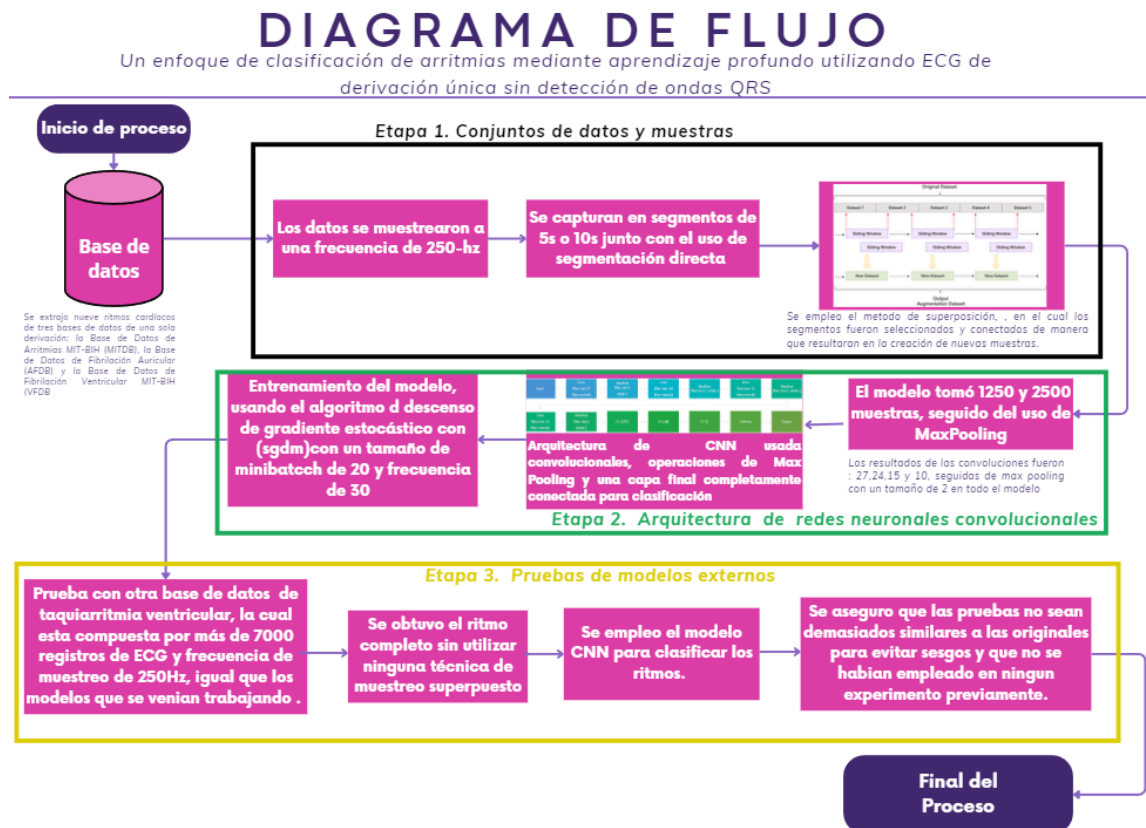


Figura 3. Diagrama de flujo para la metodología desarrollada en el artículo “An Arrhythmia classification approach via deep learning using single-lead ECG without QRS wave detection”

1.3.3. Descripción de la metodología

El estudio utilizó un modelo CNN para la clasificación de ritmos cardíacos, basado en investigaciones previas. Se entrenó con muestras de 5 y 10 segundos de tres bases de datos de PhysioNet y muestrearon a 250 Hz, estandarizando la frecuencia de muestreo. El modelo empleó varias capas de convolución y Max Pooling, entrenado durante 200 épocas con el algoritmo sgdm. Se evaluó en datos de prueba para medir su precisión. Además, se probó el modelo en la base de datos CUDB de taquiarritmia ventricular, sin superposición de muestras, para analizar su rendimiento en datos no vistos y evitar el sobreajuste. Las pruebas externas permitieron evaluar

su viabilidad en escenarios reales, probar el funcionamiento del modelo CNN para clasificar estos ritmos y con datos desconocidos; además detectar posibles problemas de sobreajuste. A medida que se aumentaron los datos utilizando el método de superposición se conocía el riesgo potencial de sobreajuste del modelo. Por otro lado es importante conocer que los datos usados no sean demasiado similares a los datos originales ya que podría ocasionar sesgos en el análisis, a esto se le suma que para garantizar la precisión de los resultados se comprueba que las muestras usadas no se habían usado previamente.

2. Referencias

[1] M. Gadaleta et al., “Prediction of atrial fibrillation from at-home single-lead ECG signals without arrhythmias”, npj Digit. Medicine, vol. 6, n.º 1, diciembre de 2023. Accedido el 21 de octubre de 2024. [En línea]. Disponible: <https://doi.org/10.1038/s41746-023-00966-w>

[2] J. Zheng et al., “Optimal Multi-Stage Arrhythmia Classification Approach”, Scientific Rep., vol. 10, n.º 1, febrero de 2020. Accedido el 21 de octubre de 2024. [En línea]. Disponible: <https://doi.org/10.1038/s41598-020-59821-7>

[3] L. Rung Liu, “An Arrhythmia classification approach via deep learning using single-lead ECG without QRS wave detection”, Heliyon, vol. 10, n.º 5, 2024. [En línea]. Disponible: <https://www.sciencedirect.com/science/article/pii/S2405844024032316>